



Рубежный контроль №1: предобработка данных

Задача: масштабирование одного числового признака; преобразование одного категориального признака методами **Label Encoding** и **One-Hot Encoding**; построение **парных диаграмм**.

Датасет: [Heart Disease Dataset \(Kaggle\)](#) — классический набор Cleveland (UCI), 303 наблюдения, 14 признаков. Локальная копия: `heart.csv` (загружена с открытого зеркала, совместимого с Kaggle-версией).

1. Описание набора данных

Признак	Описание
Age	Возраст
Sex	Пол (1 — муж, 0 — жен)
ChestPain	Тип боли в груди (категориальный)
RestBP	Давление в покое
Chol	Холестерин
Fbs	Сахар натощак > 120 мг/дл
RestECG	Результаты ЭКГ в покое
MaxHR	Макс. ЧСС
ExAng	Стенокардия при нагрузке
Oldpeak	Депрессия ST
Slope	Наклон пика ST
Ca	Число сосудов (0–3), есть пропуски
Thal	Таллий-сканирование (категориальный)
AHD	Наличие болезни сердца (Yes/No)

Датасет подходит для задания: есть **категориальные** признаки и **пропуски** (`Ca` , `Thal`).

Импорт библиотек

```
In [ ]: import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

from pathlib import Path
from sklearn.preprocessing import LabelEncoder, OneHotEncoder, StandardScaler

%matplotlib inline
sns.set(style='ticks')
```

2. Загрузка и первичный осмотр

```
In [ ]: DATA_PATH = Path('heart.csv')
if not DATA_PATH.exists():
    DATA_PATH = Path('rk1/heart.csv')

df = pd.read_csv(DATA_PATH, index_col=0)
print(f'Размер: {df.shape[0]} строк, {df.shape[1]} столбцов')
df.head()
```

Размер: 303 строк, 14 столбцов

```
Out[ ]:
```

	Age	Sex	ChestPain	RestBP	Chol	Fbs	RestECG	MaxHR	ExAng	Oldpea
1	63	1	typical	145	233	1	2	150	0	2.
2	67	1	asymptomatic	160	286	0	2	108	1	1.
3	67	1	asymptomatic	120	229	0	2	129	1	2.
4	37	1	nonanginal	130	250	0	0	187	0	3.
5	41	0	nontypical	130	204	0	2	172	0	1.

```
In [ ]: df.info()
print('\nПропуски:')
print(df.isnull().sum()[df.isnull().sum() > 0])
```

```

<class 'pandas.DataFrame'>
RangeIndex: 303 entries, 1 to 303
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Age         303 non-null    int64
1   Sex         303 non-null    int64
2   ChestPain   303 non-null    str
3   RestBP      303 non-null    int64
4   Chol        303 non-null    int64
5   Fbs         303 non-null    int64
6   RestECG     303 non-null    int64
7   MaxHR       303 non-null    int64
8   ExAng       303 non-null    int64
9   Oldpeak     303 non-null    float64
10  Slope       303 non-null    int64
11  Ca          299 non-null    float64
12  Thal        301 non-null    str
13  AHD         303 non-null    str
dtypes: float64(2), int64(9), str(3)
memory usage: 33.3 KB

```

```

Пропуски:
Ca         4
Thal       2
dtype: int64

```

3. Обработка пропусков

В данных есть пропуски в `Ca` и `Thal`. Числовой `Ca` заполним медианой, категориальный `Thal` — модой (наиболее частым значением).

```

In [ ]: df_clean = df.copy()

df_clean['Ca'] = df_clean['Ca'].fillna(df_clean['Ca'].median())
df_clean['Thal'] = df_clean['Thal'].fillna(df_clean['Thal'].mode()[0])

assert df_clean.isnull().sum().sum() == 0
print('Пропусков после заполнения:', df_clean.isnull().sum().sum())

```

Пропусков после заполнения: 0

4. Кодирование категориальных признаков

Выбран один признак для каждого метода — `ChestPain` (тип боли в груди, 4 категории, **номинальный** — порядок категорий не важен).

4.1 Label Encoding — признак Thal

Метод: `sklearn.preprocessing.LabelEncoder` — каждой категории присваивается целое число 0, 1, 2, ...

Почему Thal : три уровня таллий-сканирования (`fixed` , `normal` , `reversible`). Для демонстрации метода достаточно одного категориального столбца. Label Encoding компактен (один столбец), но **вводит искусственный порядок** между несвязанными категориями — для номинальных признаков это может вводить модель в заблуждение; здесь используем его осознанно для сравнения с One-Hot.

```
In [ ]: df_enc = df_clean.copy()

le_thal = LabelEncoder()
df_enc['Thal_le'] = le_thal.fit_transform(df_enc['Thal'])

mapping = dict(zip(le_thal.classes_, le_thal.transform(le_thal.classes_)))
print('Label Encoding Thal:', mapping)
df_enc[['Thal', 'Thal_le']].drop_duplicates().sort_values('Thal_le')
```

Label Encoding Thal: {'fixed': np.int64(0), 'normal': np.int64(1), 'reversible': np.int64(2)}

```
Out[ ]:      Thal  Thal_le
1      fixed         0
2     normal         1
3  reversible         2
```

4.2 One-Hot Encoding — признак ChestPain

Метод: `pandas.get_dummies` / `OneHotEncoder` — для каждой категории создаётся бинарный столбец (0/1).

Почему ChestPain : четыре **номинальные** категории (`typical` , `nontypical` , `nonanginal` , `asymptomatic`) без естественного порядка. One-Hot не навязывает линейную «близость» между категориями — предпочтительный способ для деревьев/линейных моделей при небольшом числе уровней.

```
In [ ]: chest_ohe = pd.get_dummies(df_enc['ChestPain'], prefix='ChestPain', dtype=int)
df_enc = pd.concat([df_enc, chest_ohe], axis=1)

print('Столбцы One-Hot для ChestPain:')
```

```
print(chest_ohc.columns.tolist())
df_enc[['ChestPain'] + chest_ohc.columns.tolist()].head()
```

Столбцы One-Hot для ChestPain:

```
['ChestPain_asymptomatic', 'ChestPain_nonanginal', 'ChestPain_nontypical', 'ChestPain_typical']
```

```
Out[ ]:
```

	ChestPain	ChestPain_asymptomatic	ChestPain_nonanginal	ChestPain_nontypical
1	typical	0	0	1
2	asymptomatic	1	0	0
3	asymptomatic	1	0	0
4	nonanginal	0	1	0
5	nontypical	0	0	1

```
In [ ]: # Эквивалент через sklearn OneHotEncoder (drop='first' – базовая категория)
ohe = OneHotEncoder(sparse_output=False, drop='first')
chest_sklearn = ohe.fit_transform(df_clean[['ChestPain']])
cols_sk = ohe.get_feature_names_out(['ChestPain'])
pd.DataFrame(chest_sklearn, columns=cols_sk, index=df_clean.index).head()
```

```
Out[ ]:
```

	ChestPain_nonanginal	ChestPain_nontypical	ChestPain_typical
1	0.0	0.0	1.0
2	0.0	0.0	0.0
3	0.0	0.0	0.0
4	1.0	0.0	0.0
5	0.0	1.0	0.0

5. Масштабирование одного числового признака

Масштабируем **Chol** (холестерин, мг/дл) с помощью **StandardScaler**

Почему StandardScaler: признак имеет разброс, отличный от других числовых столбцов (Age, RestBP). Стандартизация центрирует распределение (среднее ≈ 0 , $\sigma \approx 1$), что полезно для алгоритмов, чувствительных к масштабу (SVM, k-NN, градиентные методы). Для одного признака по условию задания достаточно одного метода.

```
In [ ]: chol_original = df_enc[['Chol']].copy()

scaler = StandardScaler()
df_enc['Chol_scaled'] = scaler.fit_transform(chol_original)
```

```

print('Параметры StandardScaler для Chol:')
print(f' mean = {scaler.mean_[0]:.2f}, std = {scaler.scale_[0]:.2f}')
print('\nСравнение (первые 5 строк):')
pd.DataFrame({
    'Chol': chol_original['Chol'].head().values,
    'Chol_scaled': df_enc['Chol_scaled'].head().values,
})

```

Параметры StandardScaler для Chol:
mean = 246.69, std = 51.69

Сравнение (первые 5 строк):

```

Out[ ]:      Chol  Chol_scaled
0    233    -0.264900
1    286     0.760415
2    229    -0.342283
3    250     0.063974
4    204    -0.825922


```

```

In [ ]: fig, axes = plt.subplots(1, 2, figsize=(10, 4))
axes[0].hist(df_enc['Chol'], bins=20, edgecolor='black', alpha=0.7)
axes[0].set_title('Chol — до масштабирования')
axes[0].set_xlabel('Chol')

axes[1].hist(df_enc['Chol_scaled'], bins=20, edgecolor='black', alpha=0.7, color='orange')
axes[1].set_title('Chol — после StandardScaler')
axes[1].set_xlabel('Chol_scaled')
plt.tight_layout()
plt.show()

```




6. Парные диаграммы (pair plot)

Для визуализации связей между признаками строим `sns.pairplot`. Полный набор из 14 столбцов перегружает график, поэтому берём подмножество: числовые признаки + целевая `AHD`.

```
In [ ]: # Целевая переменная для раскраски
df_plot = df_enc.copy()
df_plot['target'] = (df_plot['AHD'] == 'Yes').astype(int)

pair_cols = ['Age', 'RestBP', 'Chol', 'MaxHR', 'Oldpeak', 'target']
sns.pairplot(df_plot[pair_cols], hue='target', palette='tab10', diag_kind='hist')
plt.suptitle('Парные диаграммы (Heart Disease)', y=1.02)
plt.show()
```



7. Выводы

Задача	Метод	Признак	Обоснование
Масштабирование	<code>StandardScaler</code>	<code>Chol</code>	Один числовой признак с заметным разбросом; приведение к нулевому среднему и единичной дисперсии
Категории → числа (способ 1)	<code>LabelEncoder</code>	<code>Thal</code>	Компактное кодирование; демонстрация метода (осторожно с номинальными данными)
Категории → числа (способ 2)	One-Hot	<code>ChestPain</code>	Номинальный признак без порядка; отдельный бинарный столбец на категорию
Визуализация	<code>sns.pairplot</code>	подмножество числовых + <code>target</code>	Оценка корреляций и разделимости классов

Использованные библиотеки: `pandas` , `numpy` , `seaborn` , `matplotlib` , `sklearn` (импутация, кодирование, масштабирование).